Правительство Российской Федерации Государственное образовательное бюджетное учреждение высшего профессионального образования «Научно-исследовательский университет – Высшая школа экономики»

Факультет: МИЭМ

Направление: Компьютерная безопасность

Отчет по лабораторной работе №2 (алгоритмы сортировки)

по дисциплине

«Методы программирования»

Выполнил Студент группы СКБ151 Михалицын Пётр

Содержание

Описание проекта	2
Спецификация модулей	3
Алгоритмы поиска и принципы работы с классом для осуществления поиска	6
Результаты, полученные после оценки алгоритмов поиска и выводы	7
Коды модулей	10
Hash_search_db.py	10
schedule_maker.py	12
search_db.py	14
sort_db.py	15
hasher.py	16
sqlwrap.py	17
train.py	19
train_schedule.py	21
collision_analysis.py	27
hash_test.py	29
search_test.py	31
sort_test.py	

Описание проекта

Проект заключался в сравнении трех видов поиска

- 1) Линейный
- 2) Бинарный
- 3) Поиск по ключу / с использованием хеш таблицы (стандартный)

Проект содержит в себе несколько модулей, которые можно разделить на 3 типа

- 1) Основные
 - a. sort_db.py
 - b. hash_search_db.py
 - c. search db.py
 - d. schedulem maker.py
- 2) Вспомогательные
 - a. sqlwrep.py
 - b. train.py
 - c. train schedule.py
 - d. hasher.py
- 3) Тесты
 - a. collision_analysis.py
 - b. hash test.py
 - c. search_test.py
 - d. sort_test.py

Все основные модули находятся в корневом каталоге проекта

Все вспомогательные модули находятся в директории source

Все тестовые модули находятся в каталоге tests

Вся информация сохраняется в базе данных SQLite

В ходе лабораторной работы нам будут интересны только 3 модуля: search_db.py, train_schedule.py, search_test.pt; остальные подверглись незначительным изменениям после первого проекта. Посмотреть полностью весь проект можно в репозитории https://github.com/lo1ol/train-schedule

Спецификация модулей

Для начала перечислим спецификацию всех новых функций и методов.

Модуль train schedule.py и обновленный класс Schedule

```
Class Schedule:

"""

Attribute database consist wrapping database with type DatabaseWrap

:param database_name: is str, consist path to database

Class consist

Attribute db: contain all data, before using call method load database

Attribute database: contain connection with database

Special Method __init__,

Special Method __getattr _ for raise exceptions if some functions are not

called

Method load_database for establish connection with database and load all

records in list

Method unload_database for sever connection with database and load all records

in db to sqlite database

Method insert_sort for insert sorting,

Method quick_sort for quick sorting,

Method print_schedule for printing formatted schedule

Static method _ format_record for formatting record to string

Static method _ format_record for formatting record to string

Static method _ linear_search for implementation linear search

Static method _ binary_search for implementation binary search

Static method _ binary_search for implementation binary search

Static method _ binary_search for implementation binary search

Method linear_search for linear search in database

Method binary_search for binary search in database

Method convert_to_dict for add opportunity of search by key

Method convert_to_simple_hash_table for converting array to hash-table

composed via simple hash

Method convert_to_rs_hash_table for converting array to hash-table composed

via rs hash

Method simple_hash_search to search in hash-table via simple hash

Method rs_hash_search to search in hash-table via rs hash

Method rs_hash_search to search in hash-table via rs hash
```

Статический метод _linear_search для реализации линейного поиска

```
def _linear_search(db, time):
    """

Method for linear search
    :param time: for search by time in field time
    :return: list of results
    """
```

Meтод linear_search для линейного поиска в массиве записей расписаний поездов

```
def linear_search(self, time, show=False):
    """
    Method for linear search
    :param time: for search by time in field time
    :param show: for print formatted results in stdio (if no one fits print 'Not found')
    :return: list of results
    """
```

Meтод binary_search для линейного поиска в массиве записей расписаний поездов

```
def binary_search(self, time, show=False):
    """
    Method for binary search
    :param time: for search by time in field time
    :param show: for print formatted results in stdio (if no one fits print 'Not found')
    :return: list of results
    """
```

Статический метод binary search реализующий сам алгоритм бинарного поиска

```
def _binary_search(db, time):
    """

Method for binary search
    :param time: for search by time in field time
    :return: list of results
    """
```

Meтод convert_to_dict конвертирующий исходный массив в ассоциативный массив/словарь

```
def convert_to_dict(self):
    """

Method convert to dict for add opportunity of search by key
    :return:
    """
```

Метод map search реализует поиск в ассоциативном массиве

```
def map_search(self, time, show=False):
    """
    Method for search by key
    :param time: for search by time in field time
    :param show: for print formatted results in stdio (if no one fits print 'Not found')
    :return: list of results
    """
```

Модуль search_db.py позволяет осуществлять поиск в базе данных расписаний с помощью командной строки выбирая в какой базе данных мы хотим искать, хотим ли выводить результаты поиска, какой метод поиска мы хотим использовать и делает при этом замер времени. Модуль содержит единственную функцию search_db

```
def search_db():
    """
    search record in database, which path input from stdin
    :return: 0
    """
```

Вот пример работы с данным модулем:

```
Command Prompt
                                                                                                                                     :\Users\mkh19\Desktop\Projects\Programming Techniques>python search_db.py
Input database name: results/quick_sort_schedule50000.db
Show suitable records?(Y/N default -- Yes): Yes
LOADING DATABASE...
CREATING DICT..
CREATING SIMPLE HASH TABLE...
CREATING RS HASH TABLE.
Type of search(linear/binary(work only on sorted database)/map/simple/rs): linear
Type searching time (format MM-DD HH:MM): 10-10 10:11
Not found
lime of search 0.006418497775424545
Type "C" and Enter to search by new time or just Enter to exit: c
Type of search(linear/binary(work only on sorted database)/map/simple/rs): binary
Type searching time (format MM-DD HH:MM): 10-11 10:11
Time of sorting 0.00026576672672717905
Type "C" and Enter to search by new time or just Enter to exit:
:\Users\mkh19\Desktop\Projects\Programming Techniques>
```

Последний модуль search_test.py является тестовым и тестрирует на время различные алгоритмы поиска. Он содержит единственную функцию search. Результаты поиска записываются в лог-файл, который потом парсится программой, написанной в пакете mathematica. На основе лог-файла строятся все таблицы и графики

```
def search(log='logs/log_search.txt', trace=False):
    """
    Make measure of two algorithms of search and make log file according this
measure
    Measure timing of computing 5, 10, 50, 100 and so on to 10**5 of sorted
records

    :param log: path to logfile
    :param trace: flag to showing measure in standard output stream
    :return: 0
    """
```

Сравнение производилось на базах данных разных размерностей. Причем все алгоритмы поиска применялись к одним и тем же базам данных и искались одни и те же записи, чтобы исключить все непредвиденные преимущества при поиске с помощь одного алгоритма над другим

Алгоритмы поиска и принципы работы с классом для осуществления поиска

Прежде чем начать поиск следует выгрузить все данные из базы данных sqlite и создать на основе них массив. При этом для корректного поиска с помощью бинарного алгоритма следует загружать или уже отсортированную базу данных или сортировать всю базу данных перед поиском. При поиске с помощью ассоциативного массива сортировку производить не обязательно, но нужно создать ассоциативный массив перед началом поиска вызвав соответствующий метод, дабы не нарваться на исключение. Для линейного поиска никаких особенных ограничений не накладывается.

Линейный поиск ищет в нашем массиве элементы последовательно, причем даже если массив отсортирован, он продолжит поиск даже после нахождения всех записей удовлетворяющих поиску, что свидетельствует о том, что время поиска будет зависеть только от количества элементов в базе данных и не будет зависеть от местонахождения искомых записей в ней

Бинарный же поиск будет зависеть, как и от местонахождения элементов в базе данных и размера базы данных. Реализован он тривиально, как и обычный бинарный поиск.

Поиск в ассоциативном массиве реализован тривиально тоже, за основу ассоциативного массива брался объект типа defaultdict, чтобы не терять некоторые записи в случае коллизий

Результаты, полученные после оценки алгоритмов поиска и выводы

Как и следовало ожидать **линейный поиск имел линейную сложность O(N)**, связано как раз это было с тем, что все **записи просматривались последовательно**, более того немало сыграл тот факт, что поиск происходил в отсортированных массивах даже после того, когда искомые элементы были найдены.

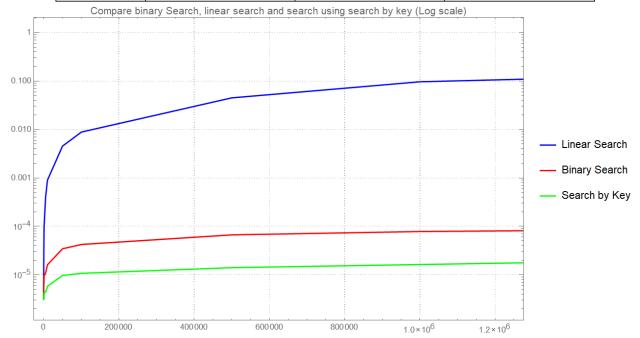
Бинарный поиск получил сложность **примерно логарифмическую сложность O(log(N)).** Связанно же это с тем, что **на каждой итерации массив делился пополам** и продолжался поиск тем же методом в нужной половинке массива.

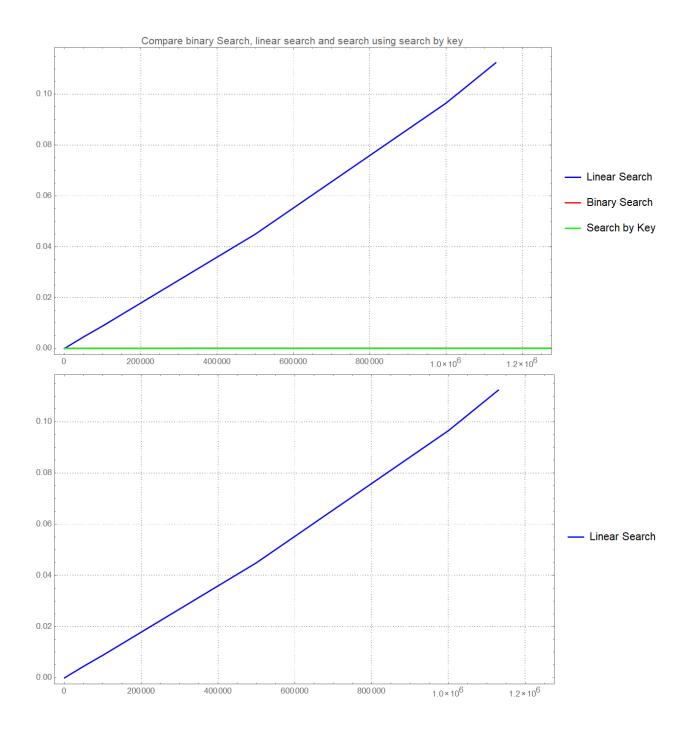
Поиск с помощью ассоциативного массива имел почти константную сложность O(1) (хоть время и увеличивалось с увеличением n, но это увеличение было настолько незначительным, что им можно пренебречь, вероятно оно было связанно с устройством самого компьютера и алгоритма поиска нужных записей в оперативной памяти + образование коллизий). Связанно это с тем, что по сути время поиска зависело только от трех параметров — преобразование строки со временем в хеш, используя стандартный алгоритм в python (операция занимает константное время), обращение по индексу в массиве (константное время). И поиск внутри коллизий (скорее всего поиск внутри них происходит с помощью бинарного поиска, но это не факт и зависит от реализации). Поэтому по идее поиск в итоге должен иметь логарифмическую сложность, но т.к., как мы узнаем из следующей лабораторной работы, число коллизий очень мало, то поиск осуществляется почти полностью за константное время.

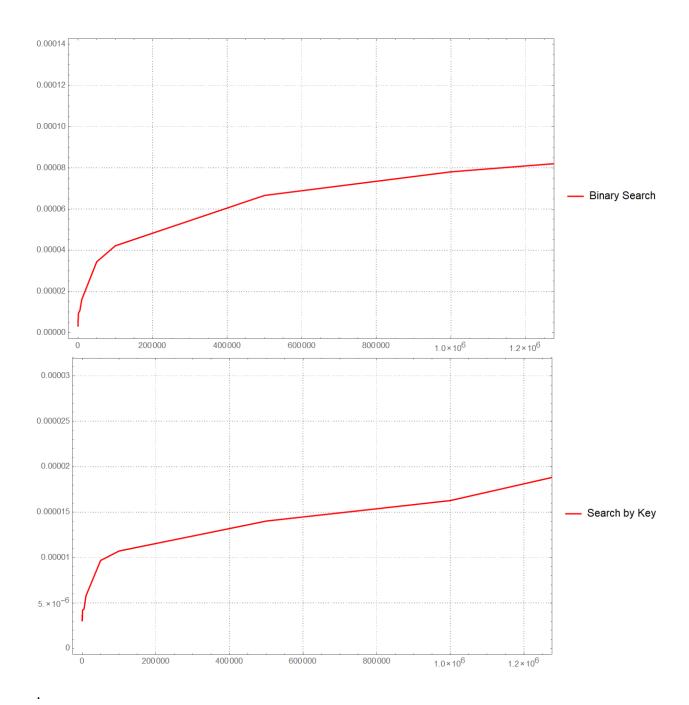
Стоит отметить, что поиск происходил в каждой базе данных 100 раз и по результатам бралось среднее выборочное и заносилось в лог-файл.

Снизу приведены графики и таблицы результатов поиска с использованием различных методов поиска

Number	Linear	Binary	Search by
	Search	Search	Key (sec.)
	(sec.)	(sec.)	
5	4.64797×10^{-6}	3.3027×10^{-6}	3.15241×10^{-6}
10	3.11575×10^{-6}	3.57029×10^{-6}	2.97646×10^{-6}
50	6.02623×10^{-6}	4.51968×10^{-6}	3.6326×10^{-6}
100	0.0000110004	5.61935×10^{-6}	3.69858×10^{-6}
500	0.0000410363	6.61639×10^{-6}	3.11209×10^{-6}
1000	0.0000992093	9.38025×10^{-6}	4.2081×10^{-6}
5000	0.00039856	0.0000108245	4.34373×10^{-6}
10000	0.000899071	0.0000160883	5.76964×10^{-6}
50 000	0.00453388	0.0000343906	9.6845×10^{-6}
100000	0.00882628	0.000042202	0.0000107255
500 000	0.044953	0.0000666295	0.0000140209
1000000	0.0965481	0.0000780881	0.0000162789
5 000 000	0.582974	0.000135436	0.0000531328







Коды модулей

Hash_search_db.py

```
from time import clock
from source.train_schedule import Schedule

def hash_search_db():
    """
    search record in database, which path input from stdin
    :return: 0
    """
    database = input('Input database name: ')
```

```
show = input('Show suitable records?(Y/N default -- Yes): ')
if show.lower() == 'n':
    show = False
elif show.lower() == 'y':
    show = True
print('LOADING DATABASE...')
schedule = Schedule(database)
schedule.load_database()
while True:
    type = input('Type of search(simple/rs/default): ')
    time = input('Type searching time (format MM-DD HH:MM): ')
    if type == 'linear':
        start = clock()
        schedule.linear_search(time, show=show)
        print('Time of search %s' % (clock() - start))
elif type == 'binary':
        start = clock()
        schedule.binary_search(time, show=show)
        print('Time of sorting %s' % (clock() - start))
elif type == 'map':
        schedule.convert_to_dict()
        start = clock()
        schedule.map_search(time, show=show)
        print('Time of sorting %s' % (clock() - start))
else:
        print('Unknown Search!')
    test = input('Type "C" and Enter to search by new time or just Enter to
exit: ')
    if test.lower() != 'c':
        break
return 0

if __name__ == "__main__":
    search_db()
```

schedule maker.py

```
def make database(name, db=None):
   travel_time TIME
   cursor.execute(cmd make table)
```

```
type = random.choice(['Express', 'Passenger'])
    time = random.randint(0, 1439)
    month = random.randint(1, 12)
    day = random.randint(1, 30)
    d time = "%02d-%02d %02d:%02d" % (month, day, time // 60, time % 60)
    if type == 'Express':
        n = random.randint(360, 540)
        t_time = "%02d:%02d" % (n//60, n%60)

else:
        n = random.randint(480, 720)
        t_time = "%02d:%02d" % (n//60, n%60)

cursor.execute(cmd_insert_field.format(train_number=i, type=type,
d_time=d_time, t_time=t_time))

connection.commit()
    connection.close()
    return name

if __name__ == '__main__':
    name = input("Type name of database: ')
    number = input("Type number of random records: ")
    try:
        make_database(name, int(number))
    except ValueError:
        print("Not an integer number!")
```

search_db.py

sort_db.py

```
from time import clock

from source.train_schedule import Schedule

def sort_db():
    """
    Sort database, which path input from stdin
    :return: 0
    """
    database = input('Input batadase name: ')
    type= input('Type of sort(quick/insert): ')
    schedule = Schedule(database)
    schedule.load_database()
    start = clock()
    if type == 'quick':
        schedule.quick_sort()
        print('Time of sorting %s' % (clock() - start))
    elif type == 'insert':
        schedule.insert_sort()
        print('Time of sorting %s' % (clock() - start))
    else:
        print('Unknown Sort!')
    sorted_data_base = input('Input name for out file or type "No" to continue without saving: ')
    if sorted_data_base != "No":
        schedule.unload_database(sorted_data_base)
    return 0

if __name__ == "__main__":
    sort db()
```

hasher.py

```
def simple_hash(value):
    """
    Simple hash function
    :param value: some string
    :return: hash of string from 0 to 4294967295
    """
    hash = 0
    for num, char in enumerate(value):
        hash += ord(char)**(num+1) % 4294967296
    return hash % 4294967296

def rs(value):
    """
    RS hash function
    :param value: some string
    :return: hash of string from 0 to 4294967295
    """
    b, a, hash = 378551, 63689, 0
    for i in value:
        hash = (hash*a+ord(i)) % 4294967296
        a *= b
    return hash % 4294967296

if __name__ == '__main__':
    from time import clock
    start = clock()
    hash1 = simple_hash('12-30_23:59')
    hash2 = simple_hash('05-12_22:13')
    print(hash1)
    print(hash2)
    start = clock()
    hash1 = rs('12-30_23:59')
    hash2 = rs('05-12_22:13')
    print(clock() - start)
    print(hash1)
    print(hash2)
    return(hash2)
    return(hash2)
```

sqlwrap.py

```
:param database name: must contain database name if database doesn't exist
:param item: is id-1 of record, which return
:return: tuple contain record with id == item+1 (without id)
:param value: tuple (train number, type of train, departure time,
```

```
Open connection with database and commit changes
and put in attribute connection connection with database
and in attribute cursor -- cursor
:return: None
"""
self.connection = sqlite3.connect(self.database_name)
self.cursor = self.connection.cursor()
```

train.py

```
:param d_time: department time
:param t_time: travel time
```

print(x.hash1)
print(x.hash2)

train schedule.py

```
:param database name: is str, consist path to database
```

```
def load database(self):
    :param name: name of database or None (if doesn't want to save changes)
    self.database = DatabaseWrap(name)
```

```
else: mid.append(i)
:param time: time for check
```

```
:param show: for print formatted results in stdio (if no one fits print
:param time: for search by time in field time
:return: list of results
:param show: for print formatted results in stdio (if no one fits print
```

```
self._show_result(result)
def convert to dict(self):
     :param time: for search by time in field time
     :param show: for print formatted results in stdio (if no one fits print
def convert to simple hash table(self):
     Method for search in to hash table by time hashing via simple hash :param time: for search by time in field time :param show: for print formatted results in stdio (if no one fits print)
```

```
'Not found')
    :return: list of results
    """

    self._verify_time_format(time)
    guess = self.rs_hash_table[rs(time) % self.hash_size]
    result = self._linear_search(guess, time)
    result = list(map(self._format_record, result))
    if show:
        self._show_result(result)
    return result
```

collision analysis.py

```
:param log: path to logfile
:param trace: flag to showing measure in standard output stream
```

hash test.py

```
def hash search(log='logs/log hash.txt', trace=False):
      :param log: path to logfile
      :param trace: flag to showing measure in standard output stream
             simple_hash_time = rs_hash_time = map_time = 0
schedule.convert_to_dict()
schedule.convert_to_simple_hash_table()
schedule.convert_to_rs_hash_table()
for _ in range(100):
    time = randint(0, 1439)
```

search test.py

```
:param log: path to logfile
   :param trace: flag to showing measure in standard output stream
ile=logfile)
ile=logfile)
```

sort test.py

```
def sort(log='logs/log sort.txt', trace=False):
   :param log: path to logfile
   :param trace: flag to showing measure in standard output stream
               schedule = Schedule(db name)
           print('-'*50, file=logfile)
       logfile.close()
```

```
if __name__ == "__main__":
    parser = optparse.OptionParser()
    parser.add_option('-t', '--trace', action='store_true', help='Trace the
measure in standard output, default is False', default =False)
    parser.add_option('-l', '--log', type='string', help='Logging measure in to
FILE, default in log_sort.txt', default='logs/log_sort.txt')
    (options, args) = parser.parse_args(sys.argv)
    sort(**options.__dict__)
```